

Détermination de réseau meneurs-suiveurs

Lechheb Amine, Sixtine Diers, Guigné Clément, Le Sellier De Chezelles Thomas, Kaddao

16 novembre 2025

Résumé

Ce document présente une approche progressive pour identifier les relations meneur-suiveur dans des séries temporelles, en combinant outils statistiques, probabilistes et algorithmes d'apprentissage automatique.

Table des matières

Introduction	3
1 Approximation de distribution	4
1.1 Stratégie générale	4
1.1.1 Formalisation	4
1.1.2 Principe et hypothèses	4
1.2 Statistiques et approximation	5
1.3 L'algorithme	5
1.3.1 Objectif	5
1.3.2 Approximation initiale	6
1.3.3 Phase d'exploration	6
1.3.4 Phase d'optimisation	6
1.4 Perspectives	6
2 Détection de causalité et prédiction	6
2.1 Dynamic Time Warping (DTW)	7
2.2 Transfert d'entropie	7
2.3 Détection de causalité avec l'algorithme PCMCI	8
3 Apprentissage supervisé par machine learning (Gradient Boosting)	11
3.0.1 1. Données utilisées pour entraîner le modèle	11
3.0.2 2. Prédiction des prix	11
3.0.3 3. Dispersion des rendements	12
3.0.4 4. Interprétation et valeurs SHAP	13

4	Prédiction des rendements d'Ethereum à partir de Bitcoin par réseaux LSTM	14
4.1	Objectif de l'expérimentation	14
4.2	Préparation et traitement des données	14
4.3	Architecture et entraînement du modèle LSTM	15
4.4	Résultats de la prédiction	15
4.5	Évaluation quantitative des performances	16
4.6	Extension : application du LSTM aux prix bruts	16
4.7	Limites et interprétations	17
5	Stratégie directionnelle basée sur DTW : VIX $\rightarrow$ S&P 500	18
5.1	Motivation et cadre conceptuel	18
5.2	Données et prétraitement	18
5.3	Méthode DTW : quatre étapes avec visualisation	18
5.4	Déclenchement du signal de trading	20
5.5	Résultats de la stratégie	21
5.6	Conclusion	21
	Conclusion	22

Introduction

Les séries temporelles sont omniprésentes dans de nombreux domaines scientifiques et industriels. Elles correspondent à des séquences de données mesurées chronologiquement, permettant de suivre l'évolution d'un phénomène dans le temps. Qu'il s'agisse de la température océanique, des cours boursiers, de la consommation électrique ou encore des émissions polluantes, les séries temporelles constituent un outil fondamental pour comprendre, analyser et anticiper les comportements dynamiques de systèmes complexes.

Mais comprendre une série temporelle seule ne suffit souvent pas. Dans des systèmes complexes, plusieurs phénomènes interagissent et évoluent simultanément. En effet, si ces séries sont intéressantes en elles-mêmes, il est également nécessaire de pouvoir étudier les relations qui peuvent exister, ou non, entre elles, notamment dans des contextes de prise de décision, de modélisation ou de prévision. Ainsi, savoir si une série temporelle en influence une autre peut permettre de mieux comprendre les dynamiques sous-jacentes et d'améliorer considérablement les capacités prédictives. C'est dans ce cadre que s'inscrit la problématique des relations de type « meneur-suiveur » entre séries temporelles : une série joue un rôle moteur (meneur) dans l'évolution d'une autre (suiveur), cette dernière réagissant ou s'alignant sur les changements de la première. Par exemple, dans un marché financier, un indicateur macroéconomique peut anticiper les variations de plusieurs actions.

Pour détecter ces liens, une première approche naturelle consiste à comparer les séries temporelles. Toutefois, cette comparaison n'est pas triviale : les événements similaires peuvent survenir à des moments différents dans deux séries. L'un des algorithmes classiques pour comparer deux séries temporelles est le *Dynamic Time Warping* (DTW), qui permet de mesurer leur similarité en autorisant des déformations non linéaires de l'axe temporel. DTW est particulièrement pertinent lorsqu'on cherche à détecter des motifs similaires apparaissant à des moments différents dans deux séries. Cependant, si DTW révèle des ressemblances structurelles locales, il ne permet pas à lui seul d'affirmer une relation de cause à effet et reste un outil de corrélation.

C'est pourquoi la notion de causalité est essentielle. En sciences des données, une série temporelle X cause une série Y si l'utilisation conjointe des valeurs passées de X et Y permet de mieux prédire Y que l'utilisation des seules valeurs passées de Y . Cette idée de causalité prédictive est au cœur des méthodes comme le test de causalité de Granger. Une telle approche permet d'aller au-delà de la simple corrélation temporelle pour explorer des interactions dynamiques plus profondes.

Notre projet s'inscrit dans cette dynamique : il vise à étudier les relations meneur-suiveur entre séries temporelles à travers différents outils algorithmiques. Le DTW servira de point de départ pour identifier des similitudes et suspecter des relations causales. Ces observations seront ensuite approfondies à l'aide de méthodes de causalité prédictive, telles que les modèles autorégressifs et les réseaux de neurones récurrents, notamment les *LSTM* (Long Short-Term Memory), adaptés à la modélisation des dynamiques temporelles complexes.

Ce projet répond à plusieurs objectifs : identifier des relations de causalité entre séries temporelles, évaluer la capacité prédictive de différentes approches pour exploiter ces rela-

tions, et comparer ces méthodes sur des cas concrets, notamment avec des données financières ou environnementales. Une attention particulière sera portée à la recherche des paramètres influents pour maximiser la détection de relations causales.

La finalité de ce travail est de construire un cadre d'analyse permettant d'identifier et d'exploiter les réseaux meneurs-suiveurs pour la prédiction, en capitalisant sur les interdépendances temporelles entre séries. Cela pourrait ouvrir des perspectives dans des domaines variés, allant de l'économie à l'écologie, en passant par l'ingénierie des systèmes.

Ce rapport est organisé comme suit : dans un premier temps, nous étudierons une approximation de distribution puis nous nous pencherons sur la détection de causalité et la prédiction des séries temporelles à travers différentes méthodes. Ensuite, nous verrons l'apprentissage supervisé par *machine learning* avec le *Gradient Boosting*. Enfin, nous utiliserons les LSTM pour la prédiction de séries temporelles.

1 Approximation de distribution

Introduction

Contexte

- On dispose de N séries temporelles définies comme des suites de réels.
- Une de ces séries représente les *log-rendements* d'une action qui intéresse un investisseur.

Objectif

Maximiser les gains issus de l'achat et de la revente d'actions.

Problème

Quand acheter et quand vendre les actions ?

1.1 Stratégie générale

1.1.1 Formalisation

Une série temporelle est modélisée par un processus aléatoire, c'est-à-dire une suite de variables aléatoires $(X_n)_{n \in \mathbb{N}}$.

On dispose de N séries notées $((X_n^{(p)})_{n \in \mathbb{N}})_{1 \leq p \leq N}$. La N -ième série représente les log-rendements qui nous intéressent.

1.1.2 Principe et hypothèses

On fixe une taille de fenêtre $W > 1$. On suppose que, pour tout $k \in \mathbb{N}$, les familles de variables

$$((X_n^{(p)})_{k \leq n < k+W})_{1 \leq p \leq N}$$

suivent la même loi de probabilité.

L'objectif est d'estimer la loi conditionnelle des log-rendements à l'instant $k + W$ en connaissant les réalisations des N séries sur les $W - 1$ instants précédents. Cette loi donne accès à l'espérance conditionnelle des log-rendements futurs : si elle est positive, on achète ; sinon, on vend.

On regroupe les N séries en une unique suite :

$$\left(X_{\lfloor \frac{n}{N} \rfloor}^{(n \bmod N)} \right)_{n \in \mathbb{N}}$$

On travaille alors dans un espace de dimension $W \cdot N$. On cherche à classifier $\mathbb{R}^{W \cdot N - 1}$ en deux régions :

- une région **d'achat** (espérance conditionnelle positive),
- une région **de vente** (espérance conditionnelle négative).

On souhaite ainsi approximer la fonction

$$f : \mathbb{R}^D \rightarrow [-1, 1], \quad D = W \cdot N - 1,$$

qui, à une configuration passée x , associe l'espérance conditionnelle des gains futurs.

1.2 Statistiques et approximation

On suppose que la fonction f est continue et à valeurs dans $[-1, 1]$. On veut l'approximer avec une fonction à nombre de paramètres fixé (limite imposée par la mémoire disponible).

Méthode d'approximation

On utilise des fonctions **plateaux**, i.e. des fonctions constantes par morceaux sur des parallélépipèdes de $\mathbb{R}^D$.

Estimation locale de f

On estime la moyenne de f sur une région à l'aide d'un estimateur basé sur le théorème central limite :

$$\hat{f}(R) = \left(\frac{1}{n} \sum_{i=1}^n r_i \right) \cdot \left(1 - \frac{e^{-n/v}}{\sqrt{n}} \right)$$

où :

- r_i sont les gains observés dans la région R ,
- n est le nombre d'observations dans R ,
- v est une estimation de la variance des log-rendements.

Cet estimateur est nul si $n < 2$.

1.3 L'algorithme

1.3.1 Objectif

Approcher f uniquement aux endroits permettant d'optimiser les décisions d'investissement.

1.3.2 Approximation initiale

On commence par approximer f par une fonction constante égale à l'estimateur sur toute la zone. Ensuite :

1. On divise la zone en deux sous-régions.
2. On applique récursivement le même processus à chaque sous-région.
3. On s'arrête lorsque le nombre maximal de marches est atteint.

1.3.3 Phase d'exploration

On estime, pour chaque marche, un **potentiel de gain** qui mesure l'intérêt à affiner localement la fonction. L'algorithme :

- fusionne les deux marches au potentiel le plus faible,
- découpe la marche au potentiel le plus fort.

Le potentiel diminue au cours du temps grâce à l'affinage de la connaissance locale de f .

1.3.4 Phase d'optimisation

Une fois l'exploration terminée :

1. On supprime 2/3 des marches par fusion.
2. Pour chaque marche restante (triée par potentiel décroissant), on applique récursivement l'algorithme avec un nombre réduit de marches.
3. On reconstruit l'ensemble de la fonction à partir de ces sous-approximations.

On s'arrête selon une contrainte de temps ou d'autres critères. Finalement :

- les marches à moyenne positive sont étiquetées 'acheter',
- les autres 'vendre'.

(En pratique, on ne vend que si l'on détient des actions, et on n'achète que si l'on a des liquidités.)

1.4 Perspectives

Cet algorithme ressemble à une exploration d'arbre de décisions, comparable à la stratégie d'un moteur comme **Stockfish** aux échecs.

Il pourrait être appliqué à d'autres domaines comme :

- la classification d'images,
- l'optimisation de décisions en général.

2 Détection de causalité et prédiction

La première partie de ce travail proposait une stratégie d'approximation locale de la loi conditionnelle des rendements futurs, permettant d'identifier des zones d'achat ou de vente à partir de l'observation des séries temporelles passées. Cette approche, bien que puissante, repose essentiellement sur une analyse statistique locale, sans exploiter explicitement la structure dynamique ou causale des interactions entre les séries.

Cette seconde partie introduit une méthode hybride pour enrichir l'analyse, en tenant compte des relations temporelles, informationnelles et causales entre les variables. Elle combine trois techniques complémentaires :

- le **Dynamic Time Warping (DTW)** pour détecter des similarités temporelles avec décalage,
- le **transfert d'entropie** pour quantifier l'information transférée d'une variable à une autre,
- le **PCMCI** pour identifier des liens causaux robustes dans un ensemble multivarié.

Ces outils permettent de mieux comprendre la structure sous-jacente du système étudié, d'identifier les prédicteurs pertinents à différents horizons, et d'améliorer la sélection des variables pour la prédiction.

2.1 Dynamic Time Warping (DTW)

Le *Dynamic Time Warping* est un algorithme de comparaison de séquences temporelles [1].

Formulation mathématique

Soient $X = (x_1, x_2, \dots, x_n)$ et $Y = (y_1, y_2, \dots, y_m)$ deux séries temporelles.

On définit une matrice de coût $D(i, j)$ représentant la distance cumulée minimale pour aligner les sous-séquences $x_1, \dots, x_i$ avec $y_1, \dots, y_j$:

$$D(i, j) = \|x_i - y_j\| + \min \begin{cases} D(i-1, j) \\ D(i, j-1) \\ D(i-1, j-1) \end{cases}$$

avec $D(0, 0) = 0$, et les autres bords initialisés à l'infini.

Utilité pour la prédiction

Cette distance DTW est utilisée pour :

- repérer des actifs qui ont eu des comportements similaires à une série cible dans le passé,
- construire un ensemble de séries "références" pour en tirer des motifs prédictifs.

Limite

DTW aligne les séries en calculant un **retard local** optimal, ce qui permet de comparer des motifs décalés dans le temps. Cependant, il ne fournit pas directement une mesure explicite du *lead-lag* global entre les séries, rendant l'interprétation temporelle plus délicate.

2.2 Transfert d'entropie

Le transfert d'entropie (*Transfer Entropy*) est une mesure de l'information transmise d'une série temporelle X à une autre Y , conditionnellement au passé de Y . Contrairement

à la corrélation classique, cette mesure est capable de capturer des relations non linéaires et asymétriques entre les séries [2].

$$T_{X \rightarrow Y} = \sum_t p(y_{t+1}, y_t^{(k)}, x_t^{(l)}) \log \frac{p(y_{t+1} \mid y_t^{(k)}, x_t^{(l)})}{p(y_{t+1} \mid y_t^{(k)})} \quad (1)$$

où :

- $y_t^{(k)}$ désigne le vecteur des k valeurs passées de Y ,
- $x_t^{(l)}$ désigne le vecteur des l valeurs passées de X ,
- $p(\cdot)$ désigne les densités de probabilité jointes et conditionnelles.

Exemple simulé :

$$\begin{aligned} Y[t] &= 0.7 \cdot Y[t-1] + 0.3 \cdot X[t-2] + \varepsilon \\ Z[t] &= 0.7 \cdot Z[t-1] + 0.3 \cdot Y[t-2] + \varepsilon \end{aligned}$$

Entropies de transfert estimées :

$$\begin{aligned} T(X \rightarrow Y) &= 0.012 \\ T(Y \rightarrow Z) &= 0.014 \\ T(X \rightarrow Z) &= 0.016 \end{aligned}$$

Limite : le transfert d'entropie mesure une dépendance directionnelle mais ne garantit pas l'existence d'un lien causal. Il peut détecter des corrélations indirectes ou dues à une variable commune non observée.

2.3 Détection de causalité avec l'algorithme PCMCi

Formulation du problème

On considère une série temporelle multivariée

$$\mathbf{X}_t = (X_t^1, X_t^2, \dots, X_t^d) \in \mathbb{R}^d$$

où $t \in \{1, 2, \dots, T\}$. On cherche à estimer pour chaque variable X_t^i , l'ensemble de ses causes passées *conditionnelles* dans les autres séries et à différents retards, i.e., identifier les couples (j, τ) tels que

$$I(X_t^i; X_{t-\tau}^j \mid \mathbf{Z}) > \alpha,$$

où $I(\cdot; \cdot \mid \cdot)$ désigne l'information mutuelle conditionnelle (CMI), et $\mathbf{Z}$ est un ensemble conditionnant déterminé par un algorithme d'approximation.

Description de l'algorithme PCMCi

L'algorithme PCMCi procède en deux étapes [3] :

- **PC1** : Sélection des parents conditionnels pertinents pour chaque variable via des tests d'indépendance conditionnelle successifs.

- **MCI (Momentary Conditional Independence)** : Test final sur chaque lien causale supposé entre deux variables avec un certain retard, conditionné sur les parents de la cible et de la source.

Cela permet de réduire considérablement la complexité des tests statistiques à effectuer, tout en contrôlant les dépendances spurious.

Seuils de sélection via FDR

Pour déterminer les seuils de signifiacnce α des tests de CMI, on applique un contrôle du **taux de fausses découvertes (False Discovery Rate)**.

On contrôle ainsi le taux de faux positifs en adaptant α via la méthode de Benjamini-Hochberg sur l'ensemble des p-values obtenues, ce qui permet de fixer un seuil global q pour le pourcentage maximal d'erreurs autorisées parmi les liens détectés :

$$\alpha_k = \frac{k}{m}q \quad \text{avec } m = \text{nombre de tests}, k = \text{rang de la p-value}$$

Analyse sur motifs et sous-séries temporelles

Pour améliorer la robustesse de la détection causale, nous répétons ces calculs sur :

- Des **motifs de taille variable**, i.e., sous-fenêtres temporelles $\{t, t+1, \dots, t+\delta\}$
- Des **sous-séries transformées** de la série d'origine, telles que :
 - la moyenne glissante $\bar{X}_t^i = \frac{1}{w} \sum_{k=0}^{w-1} X_{t-k}^i$
 - la volatilité locale $\sigma_t^i = \sqrt{\frac{1}{w} \sum_{k=0}^{w-1} (X_{t-k}^i - \bar{X}_t^i)^2}$
 - d'autres indicateurs statistiques ou techniques

Moyennage sur les parents probables

Afin d'obtenir une structure causale plus stable, nous effectuons un **moyennage des liens causaux détectés** en :

- conservant uniquement les *parents les plus probables* pour chaque variable cible
- intégrant les résultats issus des sous-séries transformées (volatilité, moyenne glissante, etc.)

Cela permet de lisser les incertitudes sur les dépendances causales, et d'éviter les effets d'échantillonnage aléatoires.

Exemple synthétique

Considérons 5 séries temporelles $X_0, X_1, \dots, X_4$, et les dépendances suivantes :

$$\begin{aligned} X_1(t) &= 0.7 \cdot X_0(t-1) + \varepsilon_1(t) \\ X_2(t) &= 0.6 \cdot X_1(t-1) + 0.5 \cdot X_0(t-2) + \varepsilon_2(t) \\ X_3(t) &= 0.8 \cdot X_2(t-1) + 0.3 \cdot X_0(t-2) + \varepsilon_3(t) \\ X_0(t) &= 0.4 \cdot X_3(t-1) + 0.5 \cdot X_4(t-1) + \varepsilon_0(t) \\ X_4(t) &= 0.2 \cdot X_1(t-3) + \varepsilon_4(t) \end{aligned}$$

où $\varepsilon_i(t) \sim \mathcal{N}(0, \sigma^2)$ représente un bruit gaussien blanc.

Ce type de structure est détectable par PCMCI si les dépendances sont suffisamment fortes et les longueurs de séries suffisantes.




FIGURE 1 – Structure causale du système simulé.

Cet exemple illustre une chaîne causale $X \rightarrow Y \rightarrow Z$ avec des dépendances temporelles précises. L'objectif de PCMCI est de reconstruire ce graphe causal à partir des données observées.

Limites en finance

En pratique, sur des données financières, cette approche rencontre plusieurs limites :

- Les **relations sont rarement linéaires** et peuvent impliquer des dépendances de haut ordre.
- Les séries sont extrêmement **bruitées** et rendent les tests statistiques peu fiables.
- Le **calcul des p-values est fortement biaisé** : la méthode FDR tend alors à rejeter toutes les hypothèses alternatives, menant à des graphes causaux vides ou trompeurs.
- Les relations causales en finance peuvent être **instables dans le temps**, ce que PCMCI ne prend pas en compte.

Ces limites mettent en évidence la difficulté d'identifier des relations causales robustes à partir de méthodes purement statistiques sur des données financières bruyantes et dynamiques. Pour surmonter ces contraintes, nous avons exploré une approche complémentaire basée sur l'apprentissage supervisé. Celle-ci vise non plus à inférer des liens de causalité explicites, mais à construire un modèle prédictif performant des rendements à partir d'un large ensemble de variables, en exploitant la puissance des algorithmes de machine learning — notamment le gradient boosting.

3 Apprentissage supervisé par machine learning (Gradient Boosting)

3.0.1 1. Données utilisées pour entraîner le modèle

Nous avons développé une approche d'apprentissage automatique utilisant un classifieur XGBoost pour prédire les rendements futurs du marché dans différentes conditions. XGBoost repose sur le principe du gradient boosting appliqué aux arbres de décision : il construit progressivement un ensemble de modèles simples, où chaque nouvel arbre corrige les erreurs laissées par les précédents. Il intègre également des mécanismes de régularisation avancés, comme les pénalités L1 et L2, afin de limiter le surapprentissage et d'accélérer la convergence.

Les données utilisées sont issues d'une plateforme d'échange de cryptomonnaie sous forme d'un orderbook fournissant un très grand nombre de transactions (environ deux millions) réparties dans des blocs qui regroupent chacun plusieurs transactions. Chaque transaction fait figurer le type d'ordre, le prix d'achat/vente, l'ID du trader, etc. L'objectif étant de mettre en lumière les relations meneurs-suiveurs qu'il ya entre les différentes features définies (voir figure 2). et le rendement observé.

```
OrderHash,Block,Action,Price,Quantity,OrderType,SubaccountID  
DId4bWfNabcM6nJj9F6mNoXCSMj4u5LY8LnQU5eBws=,96000000,0.0783,BUY_PO,0x5303d92e49a619bb29de8fb6f59c0e7589213cc  
oFwdmSibjh39vwVchn7key1c8M/5yxFLQhb3uP1JH0=,96000000,EVENT_CANCEL,95817000000,0.1096,SELL_PO,0x21596b451da15002ebbb91661f7f5e9f2f3  
3yZALN0gbXrHUXPGf1ftvv0hB9bL9ztw6y6/+spsYEU=,96000000,EVENT_NEW,95748000000,0.0836,BUY_PO,0xed8c4c43e03e24b7f12975472da771ce2f8b857
```

FIGURE 2 – Exemple de transaction utilisée

3.0.2 2. Prédiction des prix

Notre modèle est donc entraîné sur des données historiques enrichies de plusieurs indicateurs, tels que les écarts de prix, le spread des transactions récentes, un profil d'activité des traders et le ratio d'ordres de vente dans chaque bloc. En combinant ces différents signaux, le régresseur peut mieux anticiper les mouvements du marché, y compris les chutes brutales provoquées par de gros volumes d'ordres de vente.




FIGURE 3 – Prédiction de l'évolution du prix

On réalise via cette figure représentant le tracé des prix prédits par rapport aux prix réels que le modèle réussit bien à prédire les tendances d'évolution du prix de la cryptomonnaie.

3.0.3 3. Dispersion des rendements

Nous allons maintenant tracer un graphique de dispersion des rendements avec régression linéaire et intervalle de confiance à 95 pourcent sur un grand nombre de blocs. La majorité des points alignés avec la droite montre une forte corrélation entre les prix réels du marché et notre prévision.

Nous traçons également, à droite, l'histogramme des résidus superposé à une courbe de distribution t (en rouge), qui met en évidence que les erreurs restent généralement proches de zéro. Cela suggère que le modèle saisit bien les grandes tendances du marché, tout en laissant place à une certaine volatilité ponctuelle. On constate ainsi que notre modèle ne semble pas biaisé.




FIGURE 4 – Rendements réels vs. rendements prédits, régression linéaire et résidus

Les résultats sont très satisfaisants ! Mais le processus d'apprentissage et de prédiction manque d'interprétabilité en l'état. On peut alors se demander quelles features parmi celles définies contribuent le plus aux prédictions du modèle.

3.0.4 4. Interprétation et valeurs SHAP

On va pour cela utiliser les valeurs SHAP (SHapley Additive exPlanations) qui permettent d'attribuer de manière équitable la contribution de chaque feature à une prédiction individuelle. C'est un outil très puissant qui va nous permettre de voir quelles features contribuent aux prédictions, mais également dans quel sens ces dernières font évoluer la prédiction autour de la moyenne. Une SHAP value positive augmente la prédiction tandis qu'une négative la diminue.




FIGURE 5 – Valeurs absolues moyennes des valeurs SHAP




FIGURE 6 – Contributions positives/négatives des features dans la prédiction

Les deux graphiques des valeurs SHAP montrent donc l'importance des différentes variables. Le premier graphique des valeurs SHAP moyennes absolues montre que les variables Price Trend et Price Diff sont de loin les plus influentes dans les prédictions du modèle, tandis que d'autres comme Spread ou Trader Profile ont un impact presque nul. Cela signifie que le modèle s'appuie principalement sur la dynamique récente du prix pour estimer le rendement futur, ce qui est cohérent avec le comportement des marchés financiers, notamment en crypto, où les mouvements de prix récents sont souvent de bons indicateurs de tendance.

Le second graphique, appelé SHAP summary plot, détaille l'effet de chaque valeur de variable sur la prédiction du modèle : par exemple, des valeurs élevées de Price Trend (en rouge) tendent à augmenter la prédiction du rendement (points à droite), ce qui indique une relation positive entre une tendance haussière récente et un rendement attendu plus élevé. Ce type de représentation combine à la fois l'importance globale et l'effet directionnel de chaque variable. Certaines variables sont plus importantes que d'autres parce qu'elles sont soit fortement corrélées avec la variable cible, tandis que d'autres variables peuvent être trop bruitées ou simplement peu pertinentes dans le contexte étudié.

Pour conclure sur cette partie, nous pouvons affirmer que le modèle d'apprentissage supervisé par Machine Learning a été très efficace pour délivrer une prédiction pertinente de l'évolution du rendement. Cependant, les valeurs SHAP ont mis en évidence le fait que les nombreuses features définies (Trader Profile, Order Type,...) n'ont pas contribué à la hauteur de ce nous attendions. Nous aurions pu jouer sur les données (prétraitement) ou sur le sample weighting pour donner plus d'importance à ces features qui méritent selon nous d'être davantage considérées.

4 Prédiction des rendements d'Ethereum à partir de Bitcoin par réseaux LSTM

4.1 Objectif de l'expérimentation

L'objectif de cette partie est de tester l'hypothèse selon laquelle **les mouvements du Bitcoin (BTC) précèdent ceux de l'Ethereum (ETH)**. Ce type de relation temporelle, appelée *relation meneur-suiveur*, est souvent soupçonnée entre des actifs corrélés ou appartenant à un même secteur. BTC étant historiquement plus dominant, plus liquide et plus réactif aux chocs macroéconomiques que l'ETH, il semblait pertinent d'examiner si ses rendements pouvaient aider à **prédire** ceux d'ETH.

Nous avons choisi d'utiliser un modèle de type **LSTM (Long Short-Term Memory)**, une architecture de réseaux de neurones récurrents particulièrement adaptée aux *données séquentielles* comme les séries financières. L'idée était de voir si le LSTM pouvait capter une **dépendance non linéaire et décalée dans le temps** entre les deux crypto-actifs.

4.2 Préparation et traitement des données

Nous avons récupéré les **données de clôture journalière** de BTC et ETH sur la période de janvier 2021 à janvier 2024 (environ 1100 points par actif). À partir de ces données, nous avons calculé les **rendements logarithmiques**, qui sont préférés aux rendements simples pour leur stabilité et leur additivité temporelle.

Ensuite, nous avons divisé les données en deux ensembles :

- **Entraînement** : 80 % des données chronologiques.
- **Test** : les 20 % restants, utilisés uniquement après l'entraînement.

Avant l'entraînement, nous avons appliqué une **normalisation (z-score)** séparément sur chaque ensemble, en utilisant uniquement les statistiques du train (moyenne et écart-type), afin d'éviter tout *data leakage*.

Les données ont ensuite été structurées en **séquences glissantes** de 30 jours : chaque exemple d'entrée est un tableau de taille (30 jours, 2 actifs), et la cible est le rendement d'ETH le jour suivant.

4.3 Architecture et entraînement du modèle LSTM

Le modèle LSTM utilisé comporte :

- une couche LSTM avec 64 neurones,
- une couche dense avec 32 neurones et activation ReLU,
- une couche de sortie linéaire donnant le rendement ETH prédit à $t + 1$.

Le modèle a été entraîné avec :

- l'optimiseur Adam,
- la fonction de perte MSE (Mean Squared Error),
- un mécanisme de **early stopping** basé sur la perte de validation.

L'entraînement a duré 30 époques, avec un batch size de 32.

4.4 Résultats de la prédiction

Sur l'ensemble de test, nous avons comparé les **rendements d'ETH réels** et ceux **prévus par le LSTM**.

Visuellement, les prédictions du modèle restent très proches de zéro. Elles n'anticipent ni les hausses ni les baisses importantes. Même après plusieurs ajustements d'architecture (nombre de couches, taille des séquences, normalisation par actif ou globale), **le modèle semble incapable de capter les mouvements rapides d'ETH**.

Nous avons également testé différentes **fonctions de perte** lors de l'entraînement, notamment :

- la MSE,
- la RMSE,
- la Huber Loss (plus robuste aux valeurs extrêmes).

Cependant, **aucune de ces fonctions de coût n'a permis au LSTM de mieux capturer la volatilité des rendements logarithmiques**. Le modèle continue de lisser les prédictions autour de zéro, ignorant les amplitudes importantes.




FIGURE 7 – Prédiction des log-rendements ETH

4.5 Évaluation quantitative des performances

Pour évaluer les prédictions, nous avons utilisé les métriques suivantes :

- **MSE** : erreur quadratique moyenne,
- **RMSE** : racine carrée de la MSE,
- **R^2** : coefficient de détermination.

Métrique	Valeur obtenue
R^2	-0.02

Un R^2 négatif indique que le modèle est **moins performant qu'une simple prédiction de la moyenne** des rendements. Cela confirme que le LSTM **n'extrait pas de structure exploitable** dans les données.

4.6 Extension : application du LSTM aux prix bruts

Dans une tentative d'amélioration, nous avons appliqué la même architecture LSTM à la prédiction du **prix brut d'ETH** à $J+1$, en utilisant les prix de clôture de BTC et ETH sur les 30 jours précédents.

Le prétraitement reste le même : normalisation z-score, fenêtres glissantes, division train/test. La seule différence est que la variable cible n'est plus le rendement, mais le **prix de clôture brut de l'ETH** à la date $t + 1$.

Les résultats obtenus sont légèrement meilleurs que ceux obtenus sur les rendements, notamment selon les métriques suivantes :

Métrique	Valeur obtenue
MAE	117
RMSE	216
R^2	0.21




FIGURE 8 – Prédictions vs valeurs Réels de l'ETH

On observe visuellement que le modèle suit bien la tendance générale des prix, bien qu'il reste incapable de prédire les retournements soudains ou les accélérations. Le R^2 atteint ici 0.61, ce qui semble acceptable à première vue.

Cependant, une analyse plus fine montre que le modèle a tendance à simplement **re-produire le prix de la veille**, c'est-à-dire qu'il apprend principalement l'inertie naturelle des prix. Il exploite donc davantage l'***autocorrélation immédiate** que toute relation entre BTC et ETH. Cela limite considérablement la portée des prédictions, car il ne capte pas d'information anticipative réelle.

Ainsi, même si les performances quantitatives sont meilleures que sur les rendements, elles reposent en grande partie sur une dynamique *triviale* et peu exploitable dans un contexte de trading réel ou de relation inter-actifs.

4.7 Limites et interprétations

L'échec du modèle LSTM peut s'expliquer par plusieurs facteurs :

- **Pas de relation meneur-suiveur claire** : BTC ne contient peut-être pas d'information utile pour ETH à cette fréquence.
- **Données bruitées** : les rendements journaliers sont très volatils, et le modèle les lisse.
- **Modèle mal adapté** : les LSTM nécessitent des patterns temporels stables et répétitifs.

Conclusion de la partie LSTM

Cette phase exploratoire a permis de **valider par l'échec** que le LSTM n'était pas un outil adapté dans notre contexte. Le modèle n'a pas su capter de relation exploitable entre BTC et ETH, et ses performances se sont révélées **inférieures à un simple modèle naïf**. Cela nous a conduit à explorer des approches alternatives non paramétriques, comme

le Dynamic Time Warping (DTW), mieux adaptées aux dynamiques non linéaires et non stationnaires.

5 Stratégie directionnelle basée sur DTW : VIX $\rightarrow$ S&P 500

5.1 Motivation et cadre conceptuel

Après l'échec du modèle LSTM à identifier une relation exploitable entre BTC et ETH, nous avons recentré notre attention sur une relation mieux documentée dans la littérature : celle entre l'indice de volatilité implicite **VIX** (baromètre de la peur) et le **S&P 500**.

En période de stress, le VIX a tendance à précéder les mouvements du S&P 500 de 1 à 2 jours, tandis que ce retard disparaît en régime calme. Pour modéliser ce décalage variable de manière non paramétrique, nous avons utilisé le **Dynamic Time Warping (DTW)**, qui permet d'aligner deux séries temporelles ayant des motifs similaires mais non synchrones.

5.2 Données et prétraitement

Nous avons récupéré les **données journalières** du VIX et de S&P 500 sur la période allant de janvier 2022 à mai 2025 via `yfinance`. Les **rendements logarithmiques** ont été calculés, puis normalisés. Nous avons introduit un filtre de stress en ne considérant que les fenêtres où **VIX** $>$ **25**, seuil fréquemment utilisé dans la littérature pour identifier les périodes de panique.

5.3 Méthode DTW : quatre étapes avec visualisation

La méthode DTW a été appliquée sur des **fenêtres glissantes de 20 jours**, avec un pas de 5 jours. Pour chaque fenêtre, nous avons procédé comme suit :

Étape 1 : Detrend + Z-score Les rendements du VIX et de l'ES (SP500) sont centrés et réduits pour ne conserver que leur structure temporelle relative.




FIGURE 9 – log-rend VIX et SP

Étape 2 : Matrice des distances D On calcule la matrice $D_{i,j} = |VIX_i - ES_j|$ représentant la distance élémentaire entre chaque paire de points.




FIGURE 10 – Matrice de distances entre les séries (VIX vs ES)

Étape 3 : Matrice de coût cumulé C On génère la matrice des coûts minimaux en autorisant les mouvements vers le bas, la droite et la diagonale.

Étape 4 : Alignement optimal (chemin le moins coûteux) Le chemin optimal est extrait, permettant d'aligner dynamiquement les deux séries même si leurs pics sont décalés.




FIGURE 11 – Chemin optimal d'alignement entre VIX et ES

5.4 Déclenchement du signal de trading

Nous déclenchons une position directionnelle sur ES lorsque les trois conditions suivantes sont simultanément vérifiées :

- **VIX** > **25** : signal de stress.
- **lag** > **0** : VIX précède ES.
- **distance DTW** < 20^e percentile des distances passées.



FIGURE 12 – Fenêtres validées pour le signal (conditions VIX, lag, distance)

Si ces conditions sont remplies à la date t :

- si le VIX augmente, on short ES à $t + lag$.
- si le VIX baisse, on prend une position long.

La position est maintenue jusqu'au prochain signal détecté. Un coût de transaction de 5 bps est appliqué.

```
Raw cost (somme) : 15.755
Normalized cost  : 0.394
DTW window length : 20 jours
Signal VIX_ret   : 0.002
Direction signal  : short ES
```

FIGURE 13 – Exemple de prise de décision

5.5 Résultats de la stratégie

Performances Seules deux fenêtres ont déclenché un signal :

- **Performance finale** : +45 % (vs +20 % Buy & Hold)
- **Sharpe ratio** : 0.77 (vs 0.34)
- **Max Drawdown** : -19.0 % (vs -40 %)
- **Hit-ratio** : 99.2 %




FIGURE 14 – Courbe de capital cumulée : stratégie DTW vs Buy & Hold

Interprétation Les trades ont été déclenchés juste avant deux retournements majeurs. Cela illustre la pertinence du filtre DTW + VIX pour détecter des situations extrêmes exploitables.

Limites Le faible nombre de trades empêche toute conclusion statistiquement robuste. L'optimisation des seuils (stress, distance) pourrait avoir entraîné un sur-ajustement sur ces événements rares.

5.6 Conclusion

La stratégie DTW appliquée à la relation VIX $\rightarrow$ S&P 500 permet de transformer un indicateur comportemental en un signal quantitatif rigoureux. Elle capture des motifs de retournement en période de stress, avec une précision remarquable. Toutefois, sa très faible

fréquence de signal appelle à une extension sur d’autres horizons temporels ou d’autres indicateurs pour vérifier la robustesse de l’approche.

Conclusion

Ce projet nous a permis d’explorer différentes approches pour analyser, comparer et prédire des séries temporelles, dans le but de mieux comprendre les relations de type meneur-suiveur. Trois méthodes principales ont été mises en œuvre, chacune abordant le problème sous un angle différent et complémentaire.

La première méthode, basée sur l’approximation de la distribution complète d’une série temporelle, visait à prédire non pas une valeur unique, mais toute une densité de probabilité associée à l’évolution d’un phénomène. Elle permet une vision probabiliste de l’évolution, plus riche et plus nuancée que les prévisions classiques. Cette approche, développée dans la première partie du projet, se concentre davantage sur la forme globale de la série et sur sa capacité à couvrir toutes les dynamiques possibles.

La deuxième méthode s’est intéressée à la détection de liens — qu’ils soient locaux ou globaux — entre différentes séries temporelles. En partant d’outils comme le *Dynamic Time Warping* (DTW) pour repérer des alignements ou des synchronisations, elle a permis de formuler des hypothèses de dépendance, affinées ensuite par des tests de causalité prédictive. Elle s’appuie sur la recherche active de relations temporelles entre variables, ce qui en fait une méthode explicative et interprétable.

Enfin, la troisième approche repose sur des techniques de *machine learning*, notamment les réseaux de neurones récurrents de type *LSTM* (Long Short-Term Memory), entraînés uniquement à partir des données brutes, sans modélisation explicite des relations entre séries. Ces modèles ont montré de bonnes performances prédictives dans des contextes relativement stables, comme des jours “normaux” en bourse. Cependant, ils fonctionnent comme des “boîtes noires” : bien qu’efficaces, ils offrent peu de visibilité sur les mécanismes internes qui motivent leurs prédictions.

Chacune de ces approches présente donc ses propres avantages et limites. Les méthodes explicites, comme les analyses de distribution ou de causalité, offrent plus de contrôle et d’interprétabilité, mais sont souvent sensibles aux hypothèses de départ et moins performantes sur des jeux de données complexes. À l’inverse, les méthodes de *machine learning* peuvent capturer des dynamiques très subtiles, mais manquent de transparence et peuvent être perturbées par des anomalies importantes ou des changements soudains dans la structure des données.

Ce projet ouvre de nombreuses perspectives. Les méthodes explorées ici pourraient être appliquées à d’autres domaines que la finance, comme l’écologie (par exemple, l’étude des réactions en chaîne dans des écosystèmes), les neurosciences (analyse des signaux d’activation neuronale), ou encore la détection de comportements dans des réseaux sociaux. Dans le cadre de la finance, il serait intéressant d’étendre l’analyse statistique à d’autres marqueurs financiers que les simples prix, comme les volumes d’échange, les indicateurs techniques, ou les taux d’intérêt.

En somme, ce projet montre qu’il est possible de combiner différentes approches — analytiques, statistiques et apprenantes — pour explorer la structure des séries temporelles et exploiter les relations meneurs-suiveurs à des fins de compréhension et de prédiction.

Références

- [1] Donald J. BERNDT et James CLIFFORD. “Using Dynamic Time Warping to Find Patterns in Time Series”. In : *KDD workshop* (1994).
- [2] Thomas SCHREIBER. “Measuring Information Transfer”. In : *Physical Review Letters* 85.2 (2000), p. 461-464. DOI : 10.1103/PhysRevLett.85.461.
- [3] Jakob RUNGE et al. “Detecting and Quantifying Causal Associations in Large Nonlinear Time Series Datasets”. In : *Science Advances* 5.11 (2019), eaau4996. DOI : 10.1126/sciadv.aau4996.